Prédire et recommander la culture adaptée aux conditions saisies

Rapport métier · Agritech Answers · Projet 12 · Novembre 2026
J. Bessire, Data Scientist Machine Learning

L'essentiel en quatre points

- L'application estime le **rendement d'une culture** (en tonnes par hectare) et **classe les cultures** les plus adaptées aux conditions saisies.
- Elle s'appuie sur quatre facteurs/features : la **culture**, la **pluie annuelle**, la **température moyenne** et la quantité de **pesticides par hectare**.
- Les résultats sont **indicatifs** : les données disponibles à la modélisation sont actuellement par exemple des moyennes par pays et par année, pas des mesures de parcelle.
- Pour aller plus loin, il faudrait d'autres données réelles et plus localisées en ajoutant le type de sol, irrigation, engrais, météo locale, …

1. Contexte et objectif

Un agriculteur doit choisir **quoi planter** et anticiper **ce que sa parcelle va produire**. *Agritech Answers* a développé une application web qui l'aide sur ces deux questions :

- **Prédiction**: je choisis une culture, je renseigne les conditions de ma parcelle (pluie, température, pesticides) et j'obtiens une estimation chiffrée du rendement
- **Recommandation**: je renseigne seulement les conditions. L'application simule toutes les cultures prises en compte par le modèle qui me les présente classées, de la plus adaptée à la moins adaptée (vis-à-vis du rendement).

L'agriculteur a accès à une simple page web (App Streamlit), avec des curseurs et des boutons. Les calculs sont effectués par un service dédié (une API).

Application en ligne : https://ocprojet12-agritech-yield.streamlit.app/

2. Les données

Deux jeux de données étaient fournis. Ils sont très différents, voici ce qui a guidé les choix:

	Jeu A: rendements réels par pays	Jeu B: parcelles simulées
Contenu	Rendement, pluie, température et pesticides par pays, culture, année et rendement	Un million de parcelles: pluie, température, sol, irrigation, engrais, météo dominante, rendement
Origine	Données réelles (FAO et sources climatiques), 1990 à 2013, 101 pays, 10 cultures	Données **synthétiques** (générées artificiellement par ordinateur)
Limites	Nombre de facteurs/features limité et il s'agit seulement d'informations moyennes à l'échelle d'un pays,	Aucun pays ni année et seulement 4 cultures commune au 10 du Jeu A => impossible à relier au jeu A Données synthétiques qui ne sont absolument pas représentatives de la réalité
Usage retenu	**Construction du modèle**	**Liste de facteurs/features importantes**

Pourquoi ne pas les avoir fusionnés ? Il n'existe aucun point commun (ni pays, ni année) pour rapprocher une ligne du jeu A d'une ligne du jeu B sans inventer de lien.

Surtout, le jeu B est entièrement simulé avec de simples variations de valeurs équitablement distribués => ses valeurs ne peuvent pas être transposées à des parcelles réelles.

Le jeu A a donc été choisi pour **construire** le modèle.

Préparation des données.

- Rendements convertis en **tonnes par hectare**.
- Pesticides: le jeu donne un total national, peu parlant pour une parcelle. Nous avons utilisé une valeur **rapportée à l'hectare** (kg par hectare) issue d'un autre fichier de source FAOSTAT (Food & Agriculture Organization).
- L'année 2003 est absente des données de pluie : elle n'a pas été reconstituée, il reste 23 années.
- Une ligne par pays, culture et année: 1330 lignes au total.

Ce qui manque dans les données réelles, et que le jeu simulé suggère d'avoir: **le type de sol, l'irrigation (oui/non), l'engrais (oui/non) et la condition météo dominante**. Voir la section 7.

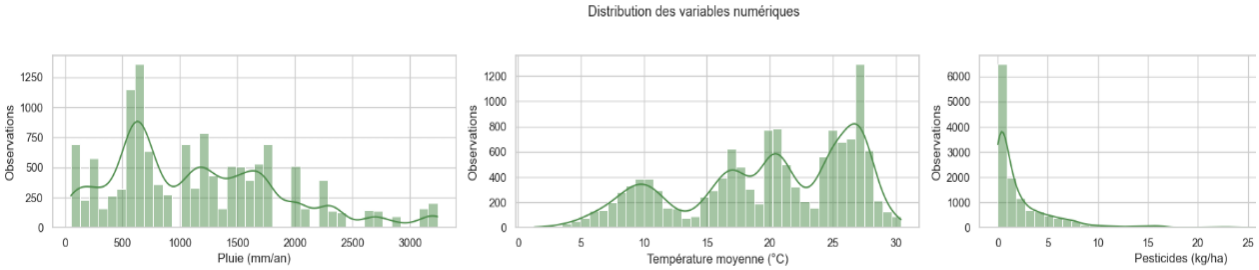
3. Distribution & Corrélation (Variables et cible) + Importance (Variables)

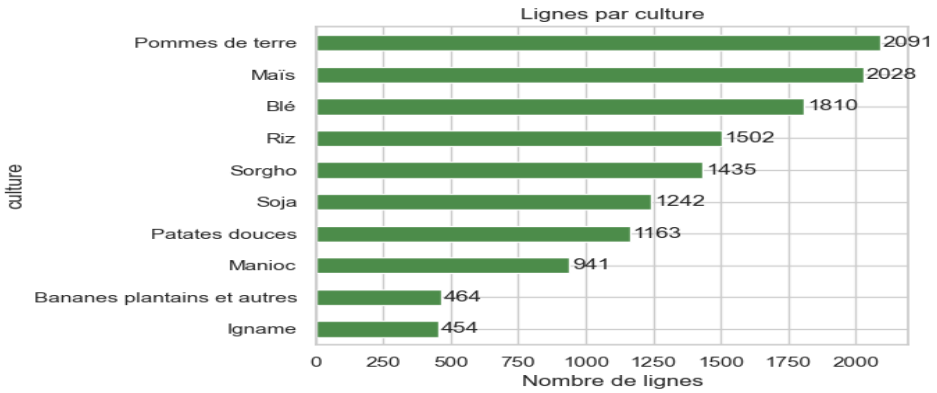
Quatre facteurs alimentent le modèle (valeur moyenne annuelle par pays):

- **La culture** *(10 cultures différentes)*
- **Pluie**
- **Température**
- **Pesticide**

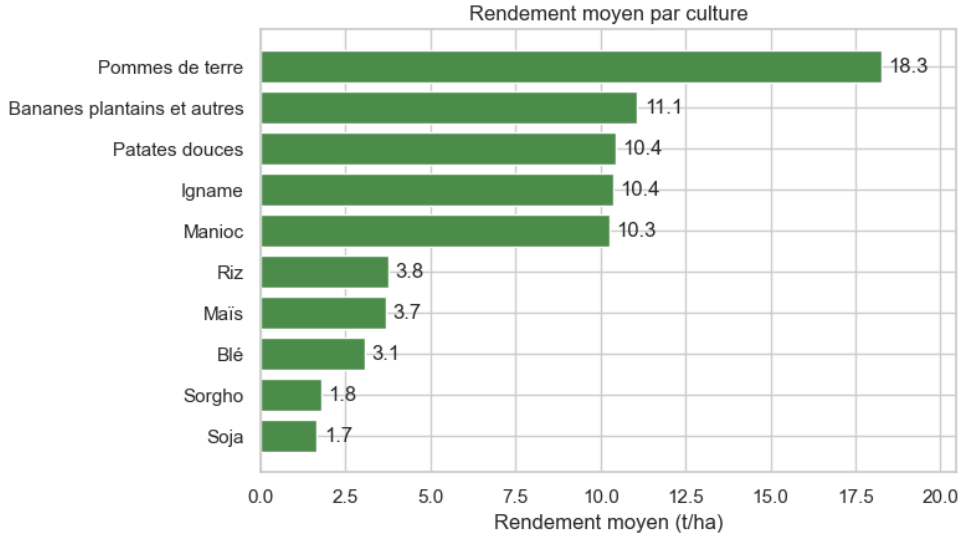
La cible: **Rendement**

a) ***Distribution des variables***



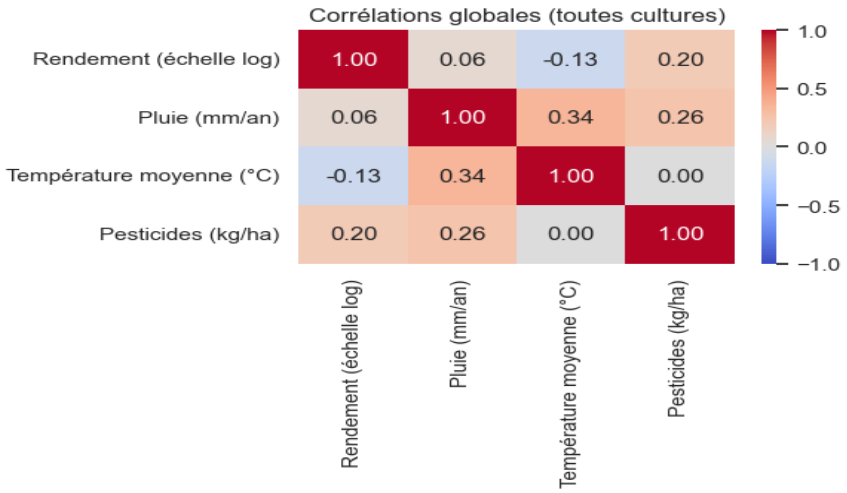


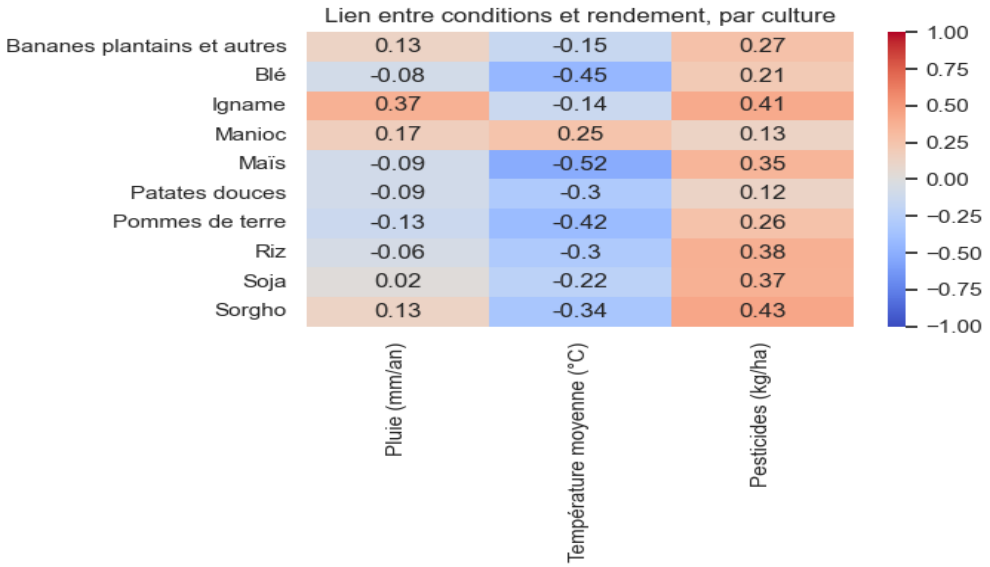
b) ***Rendement moyen par culture***



Attention : des tonnes par hectare ne se comparent pas d'une culture à l'autre (une tonne de pommes de terre, riche en eau, n'a la même valeur marchande qu'une tonne de riz, de blé ou maïs). Classer les cultures sur le rendement brut favoriserait toujours les mêmes cultures, d'où l'intérêt de comparer chaque culture **à sa propre référence** (écart en % vs son rendement moyen) comme proposer par l'application (voir section 5), et envisager de passer en valeur économique.

c) ***Corrélations-Liens entre variables et la cible***

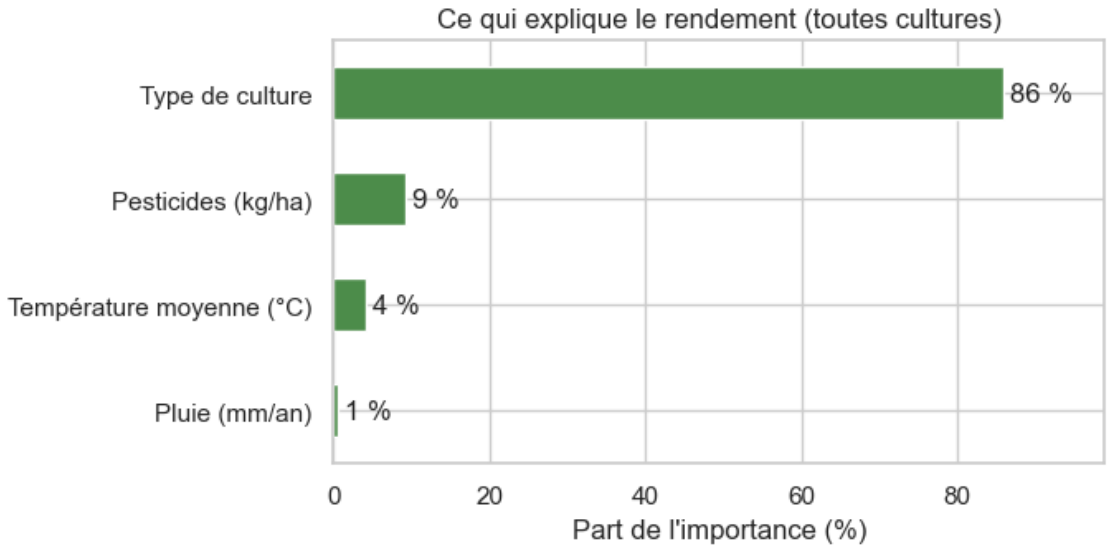


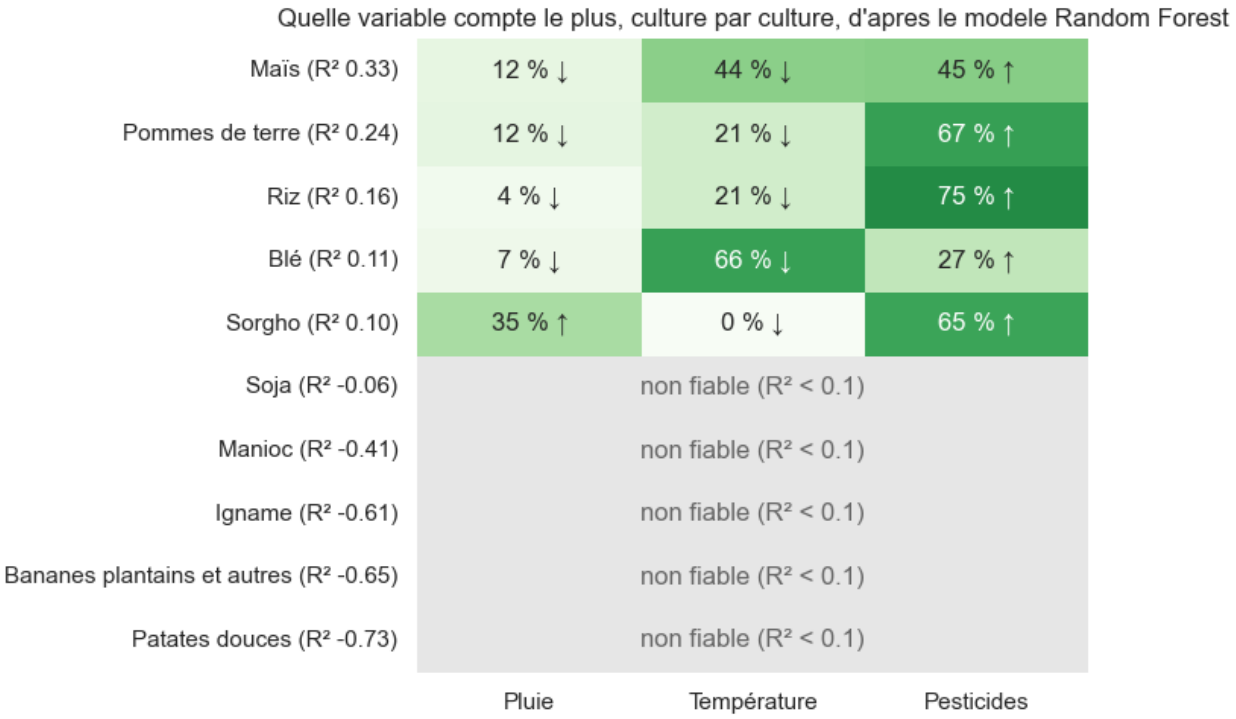


Lecture: corrélation proche de 0 = pas de lien linéaire net; positive = le rendement monte avec la variable.
Attention, les corrélations restent modérées et ne prouvent pas une causalité : pluie et température sont des moyennes nationales par pays, donc elles reflètent aussi les différences entre pays (climat, niveau d'équipement, etc.).

d) ***Importance des variables***

Pour estimer l'importance des variables on a utilisé le modèle RandomForest, validé avec des pays jamais vus à l'entraînement (GroupKFold par pays) pour une estimation honnête de ce qu'on peut attendre sur une nouvelle parcelle.





e) ***Synthèse***

Rendement médian : de 1.2 t/ha (Sorgho) à 16.2 t/ha (Pommes de terre).
Corrélations globales avec le rendt (log): pluie +0.06, température moyenne -0.13, pesticides +0.20.
Variable la plus influente: type de culture (86 % de l'importance), puis pesticides (9 %) et température moyenne (4 %).
Cultures modélisables de façon fiable ($R^2 \geq 0.1$) : Maïs, Pommes de terre, Riz, Blé, Sorgho. Les autres dépendent surtout du pays.
Culture la plus sensible à pluie : Sorgho (35 % de son importance, R^2 0.10).
Culture la plus sensible à température moyenne : Blé (66 % de son importance, R^2 0.11).
Culture la plus sensible à pesticides : Riz (75 % de son importance, R^2 0.16).
Fiabilité : $R^2 = 0.64$ sur pays jamais vus (contre 0.95 avec un split aléatoire, trop optimiste).

4. Résultats du modèle

Nous avons comparé quatre approches : une **référence basic** (qui prédit toujours le rendement moyen), un **modèle linéaire** (Ridge) et quatre **modèles à base d'arbres de décision** (Random Forest, Gradient Boosting, XGBoost et LightGBM). Le plus prometteur a ensuite été réglé par essais systématiques (recherche aléatoire de réglages). Chaque essai est enregistré dans MLflow, un journal qui garde les réglages et les scores.

Le modèle est jugé sur des données **qu'il n'a jamais vues** (jeu de test = pays non présent dans le dataset d'entrainement des modèles), et l'expérience est reproductible (seed = 42).

Métrique	*Ce que ça mesure*	*Comment la lire*
cv_rmse	Erreur moyenne de prédiction (en t/ha) en validation croisée sur le train, avec des pays séparés.	**Critère de sélection du modèle.** Plus bas = mieux. Les grosses erreurs pèsent davantage.
cv_mae	Erreur absolue moyenne (t/ha), pareil en validation croisée.	La plus parlante : "le modèle se trompe en moyenne de X t/ha".
cv_r2	Part de la variabilité du rendement expliquée, en validation croisée.	1 = parfait, 0 = pas mieux que la moyenne.
test_rmse / test_mae / test_r2	Les mêmes mesures sur le jeu de test, jamais utilisé pour choisir ou régler.	Vérification finale de la généralisation, ils ne servent pas à choisir.
gap_rmse	RMSE test moins RMSE train.	Indicateur d'overfitting : plus il est proche de 0, moins le modèle a mémorisé.
reco_top1	Part des (pays, année) où la culture classée 1re par le modèle est vraiment effectivement la meilleure.	Mesure l'utilité de /recommend.
reco_top1_random	Même taux avec un choix au hasard	Sert de seuil : reco_top1 doit être nettement au-dessus.

runs/metrics	cv_rmse	cv_mae	cv_r2	test_rmse	test_mae	test_r2	gap_rmse	reco_top1	reco_top1_random
baseline_dummy_mean	8.113	5.212	-0.110	8.965	5.421	-0.109	0.779	0.066	0.227
baseline_item_mean	5.545	3.381	0.483	5.881	3.162	0.523	0.367	0.151	0.227
ridge	7.126	3.519	-0.066	6.145	3.233	0.479	1.125	0.149	0.227
tuned_random_forest	4.873	2.943	0.597	4.351	2.545	0.739	0.786	0.252	0.227
tuned_gradient_boosting	4.791	2.894	0.607	4.158	2.492	0.761	0.196	0.347	0.227
tuned_xgboost	4.731	2.866	0.617	4.216	2.496	0.755	0.177	0.353	0.227
tuned_lightgbm	4.720	2.865	0.618	4.285	2.524	0.747	0.630	0.448	0.227

Modèle choisi: LightGBM a globalement les meilleurs metrics dont cv_rmse (= critère de selection), à noter que xgboost a des résultats légèrement supérieur sur le dataset de test.

MLFlow => Voir les screenshots dans le livrables

5. L’Application Agritech d’Aide à la décision agricole

Techniquement l’application est scindé en 2 : d’un coté l’interface utilisateur (l’App Streamlit - voir screenshot ci-dessous) et de l’autre le service de calcul (l’API qui contient et le modèle validé) qui répond aux questions transmises par l’App Streamlit: “quel rendement pour cette culture avec ces paramètres?” et “quelle culture favoriser pour ces paramètres?”



Fonctionnalité **Prédiction** (paramètres : culture, pluie, température, pesticides) => retourne le **Rendement prédit en t/ha** ainsi que **l’Écart vs rendement moyen de la culture** (+23% par rapport à la norme pour cette culture)

Fonctionnalité **Recommandation (**paramètres : pluie, température, pesticides + classement par rendement ou écart vs norme) => retourne la liste des cultures conseillées, classée par rendement ou écart de rendement vs norme

6. Recommandations agronomiques

Comment est fait le classement ? Pour chaque culture possible, le modèle simule le rendement dans vos conditions, puis le compare au **rendement habituel de cette culture**. Le classement affiche donc l'écart en % : une culture à +20 % produit 20 % de plus que sa moyenne dans vos conditions. C'est plus juste que de comparer des tonnes brutes (les pommes de terres serait quasiment toujours en tête des reco). Mais on peut aussi trier par rendement brut (en tonnes/ha).

Les cultures pour lesquelles la pluie ou la température saisie sort de ce qui a été observé sont **écartées et signalées** : le modèle ne doit pas répondre sur des conditions qu'il n'a jamais rencontrées.

Exemples (issus de l'application)

Scénario	Conditions	Culture(s) en tête
1. Chaud et pas trop sec	1100 mm, 26 °C, 0.5 kg/ha	Manioc, Igname et Bananes Plantains
2. Froid et pas trop sec	1100 mm, 2.5 °C, 0.5 kg/ha	Blé et Pommes de terre
3. Tempéré + Pesticides	1600 mm, 13 °C, 7 kg/ha	Sorgho, Maïs et Riz

Ce qu'il faut en retenir :

- Privilégier la culture qui s'écarte le plus **au-dessus de sa norme** dans vos conditions.
- Se méfier des cultures proches des limites observées (pluie ou température extrêmes) : l'estimation y est moins sûre.
- Utiliser le résultat comme **aide à la décision**, à croiser avec la connaissance du terrain.

7. Limites, prudence et pistes d'amélioration

Ce que le modèle ne sait pas faire

- **Données trop globales** : la pluie et la température sont des moyennes annuelles par pays, quelle que soit sa taille. Dans un grand pays, deux régions peuvent avoir des climats très différents.
- **Pluie identique chaque année** : dans ce jeu, la pluie est une moyenne qui ne change pas d'une année à l'autre. Le modèle ne peut donc pas apprendre l'effet d'une année sèche ou humide : la pluie sert surtout à situer le type de climat.
- **Pas de sol, d'irrigation, d'engrais** ni de météo locale dans les données réelles.
- **Pas de prix ni de coûts**: nous recommandons en rendement, pas en profit.
- **Estimation indicative**: en dehors des plages observées, l'application avertit ou écarte la culture.

Pour aller plus loin, il faudrait :

- des données de parcelle réelles : **type de sol, irrigation (oui/non), engrais (oui/non), condition météo dominante**.
- une météo plus fine (région, parcelle, mois par mois) ;
- des prix de vente et des coûts, pour passer du rendement au revenu puis au profit.

8. Fiabilité technique

- L'applicatif principal (l'API) est **testée automatiquement** à chaque modification : si un test échoue, la mise en ligne est bloquée.
- Quand tous les tests passent, la nouvelle version est **construite puis déployée automatiquement**.
- Résultat : ce que vous utilisez est toujours une version qui a été vérifiée.